


Telco Customer Churn

Predição de Cancelamento de Clientes

Como o machine learning pode identificar clientes em risco antes que eles cancelem o serviço

Diego Kaique · Data Science · 2026



Qual problema estamos resolvendo?

Empresas de telecomunicações perdem receita toda vez que um cliente cancela o contrato — isso é chamado de **churn**.

O desafio: identificar **QUEM vai cancelar ANTES** que isso aconteça, para agir com ações de retenção no momento certo.

26.5%

Taxa de Churn

dos clientes cancela o serviço

\$780

Receita Perdida

por cliente ao ano

5x

Custo de Aquisição

mais barato reter do que adquirir um novo
cliente

Os dados utilizados

Dataset

IBM Telco Customer Churn

Fonte: Kaggle

Registros: 7.043 clientes

Colunas: 21 variáveis


Variável alvo: Churn (Yes / No)

	customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	OnlineSecurity	...	TechSupport	StreamingTV	StreamingMovies
0	7590-VHVEG	Female	No	Yes	No	1	No	No phone service	DSL	No	...	No	No	No
1	5575-GNVDE	Male	No	No	No	34	Yes	No	DSL	Yes	...	No	No	No
2	3668-QPYBK	Male	No	No	No	2	Yes	No	DSL	Yes	...	No	No	No
3	7795-CFOCW	Male	No	No	No	45	No	No phone service	DSL	Yes	...	Yes	No	No
4	9237-HQITU	Female	No	No	No	2	Yes	No	Fiber optic	No	...	No	No	No
5	9305-CDSKC	Female	No	No	No	8	Yes	Yes	Fiber optic	No	...	No	Yes	Yes
6	1452-KIOVK	Male	No	No	Yes	22	Yes	Yes	Fiber optic	No	...	No	Yes	No
7	6713-OKOMC	Female	No	No	No	10	No	No phone service	DSL	Yes	...	No	No	No
8	7892-POOKP	Female	No	Yes	No	28	Yes	Yes	Fiber optic	No	...	Yes	Yes	Yes
9	6388-TABGU	Male	No	No	Yes	62	Yes	No	DSL	Yes	...	No	No	No

Exemplos de variáveis

Variável	O que representa
tenure	Tempo de contrato em meses
Contract	Tipo de contrato (mensal/anual)
MonthlyCharges	Valor cobrado por mês (USD)
TechSupport	Possui suporte técnico
InternetService	Tipo de internet contratada
Churn	Cancelou? (variável alvo)

Como o projeto foi estruturado



EDA

Feature Eng.

Modelagem

SHAP

EDA

- Dependências e Bibliotecas
- Carregamento e Limpeza
- Distribuição da Variável Alvo
- Análise Numéricas × Churn
- Análise Categóricas
- Tenure — Período Crítico
- Resumo de Insights

Feature Engineering

- Limpeza de Colunas
- Encoding Binário
- One-Hot Encoding
- Features Derivadas
- Normalização e Split

Modelagem Preditiva


- Baseline (Hiperparâmetros Padrão)
- Otimização com Optuna
- Retreinamento
- Comparativo de Métricas
- Curvas ROC
- Matrizes de Confusão
- Feature Importance
- Validação Cruzada
- Impacto Financeiro

Interpretabilidade com SHAP

- Cálculo dos SHAP Values
- Summary Plot
- Bar Plot
- Dependence Plot
- Waterfall Plot
- Force Plot


O que os dados revelaram

Antes de qualquer modelo, a análise exploratória mostrou os fatores mais associados ao cancelamento de clientes.




Distribuição de Churn

26.5% dos clientes cancelaram o serviço, representando um volume significativo de perda de receita



Taxa por Contrato

Contratos mensais apresentam 42.7% de churn, muito acima da média geral




Período Crítico

Primeiros 12 meses mostram maior concentração de cancelamentos — momento de máxima vulnerabilidade

Modelos treinados e comparativo de métricas

Três algoritmos foram treinados e otimizados com Optuna (50 tentativas por modelo, validação cruzada 5-fold). O **XGBoost** **apresentou o melhor desempenho** em todas as métricas.

Modelo	AUC-ROC	Recall	F1
Regressão Logística	0.8412	0.7662	0.6132
Random Forest	0.8389	0.7403	0.6018
XGBoost	0.8470	0.8182	0.6418



Hiperparâmetros otimizados com Optuna

O Optuna usa o algoritmo TPE (Tree-structured Parzen Estimator) para buscar hiperparâmetros de forma inteligente, aprendendo com as tentativas anteriores e tornando a otimização mais eficiente que uma busca exaustiva.

Melhores parâmetros encontrados (XGBoost)

Hiperparâmetro	Valor
n_estimators	450
max_depth	5
learning_rate	0.02
subsample	0.85
colsample_bytree	0.7




Configuração


- 50 trials por modelo
- Validação cruzada 5-fold
- Métrica: AUC-ROC
- Direção: maximizar

Por que o modelo decide assim? — SHAP Values

O SHAP atribui a cada variável uma contribuição individual para cada predição. **Vermelho = aumenta risco de churn**. **Azul = reduz risco de churn**.



Impacto e direção de cada feature



Explicação individual: cliente de alto risco

- **tenure** e **MonthlyCharges** são as variáveis de maior impacto
- Contratos mensais aumentam significativamente o score de churn
- Clientes com mais serviços contratados têm menor risco de sair

Quanto o modelo economiza?

Cada churn não detectado representa receita perdida. Com o modelo em produção, a empresa consegue priorizar quem recebe ação de retenção — reduzindo custo e maximizando retorno.

287

Churns Detectados

Verdadeiros positivos no conjunto de teste

\$223K

Economia Bruta

Estimativa anual de receita preservada

\$153K

Lucro Líquido

Após custo das campanhas de retenção

ⓘ Premissas: Receita média \$65/mês por cliente · Custo de campanha \$50/cliente · Estimativas baseadas no conjunto de teste (20% do total — 1.408 clientes)

O que fazer com esse modelo?

1

Primeiros 12 meses

Priorizar campanhas de retenção logo no início do contrato
— período de maior risco identificado no EDA

2

Contratos mensais

Oferecer migração para planos anuais ou bienais aos
clientes de alto risco — reduz churn em até 15x

3

Suporte técnico

Incentivar contratação do suporte técnico como fator de
aumento do custo de troca (switching cost)

4

Fibra óptica

Revisar a experiência dos usuários de fibra, que apresentam
taxa de churn acima da média geral

Projeto disponível no GitHub

Todos os notebooks, dados processados e documentação estão disponíveis publicamente para consulta.

Tecnologias: Python · Pandas · Scikit-learn · XGBoost · Optuna · SHAP · Matplotlib · Seaborn

github.com/diegokaique



Diego Kaique · Data Scientist